Aplicação de métodos de aprendizado de máquina para identificação de regiões genômicas associadas a características agronômicas em arroz (*Oryza sativa*)

Renata Dourado Roque, Camila Ferreira Azevedo, Ana Carolina Campana Nascimento, Moyses Nascimento

Resumo

A Associação Genômica Ampla (GWAS) é empregada para identificar associações entre marcadores e características quantitativas, contribuindo para o melhoramento genético. Tradicionalmente, baseia-se em modelos lineares mistos (MLM), que assumem relações lineares entre marcadores e fenótipos. Entretanto, características complexas podem apresentar efeitos não lineares e interações gênicas que limitam o desempenho desses modelos. Nesse contexto, métodos de aprendizado de máquina (ML) são uma alternativa para identificar marcadores relevantes. O objetivo deste trabalho foi comparar e integrar métodos de ML e GWAS para identificar e priorizar regiões genômicas associadas a características agronômicas em arroz. Foram analisados 413 acessos genotipados com 36.901 SNPs e fenotipados para resistência à brusone (RB), largura da folha bandeira (LFB), flores por panícula (FP) e comprimento da panícula (CP). Foram avaliados os métodos Árvore de Decisão, *Bagging*, *Boosting*, *Random Forest* e *Multivariate Adaptive Regression Splines* (MARS), *Mixed Linear Model* (MLM) e *FarmCPU*. A importância dos marcadores foi estimada por validação cruzada e sua significância foi obtida por testes de permutação, permitindo estimar valores-*p* empíricos com correção para múltiplos testes. As medidas de importância foram normalizadas e sintetizadas por regiões genômicas. Foram identificadas cinco regiões relevantes, sendo duas associadas à RB, uma à LFB, uma a FP e uma ao CP. As regiões associadas à RB e à LFB foram identificadas por múltiplos métodos, indicando maior consistência. Os resultados indicam que a integração de diferentes métodos permite priorizar regiões com maior robustez, pois regiões identificadas por múltiplas abordagens apresentam evidências mais consistentes de associação. Por outro lado, regiões detectadas por métodos específicos podem refletir diferentes componentes genéticos das características avaliadas, ampliando o conjunto de regiões candidatas para validação funcional.

Palavras-chave: GWAS; Melhoramento genético; Teste de permutação; Efeitos não lineares.